

UNIVERSITÀ DEGLI STUDI DI PADOVA
DIPARTIMENTO DI SCIENZE STATISTICHE
CORSO DI LAUREA TRIENNALE IN
STATISTICA PER LE TECNOLOGIE E LE SCIENZE



RELAZIONE FINALE

Utilizzo del nomogramma per il tumore al seno

Relatore Prof.ssa Laura Ventura

Correlatore Dott. Rocco Cappellesso

Laureando: Leonardo Perin
Matricola: 2067216

Anno Accademico 2024/2025

Indice

Introduzione	1
1 Tumore al seno	3
1.1 Carcinoma della mammella	3
1.1.1 Linfonodo sentinella	5
1.2 I dati	6
1.2.1 Dati mancanti	9
2 Analisi esplorative	11
2.1 Analisi bivariate	18
3 Nomogramma	33
3.1 Modelli lineari generalizzati	33
3.2 Modelli per dati binari	34
3.2.1 Applicazione del modello ai dati	35
4 Conclusioni	41
 Bibliografia	 43

Introduzione

Il tumore al seno, noto anche come carcinoma mammario o tumore alla mammella, è una crescita anomala e incontrollata di cellule all'interno della ghiandola mammaria.

Nella prima fase (stadio 1) la neoplasia è limitata al tessuto adiposo del seno. Nelle fasi seguenti il tumore si estende nelle immediate vicinanze (stadio 2). Dopo di che si estende ai tessuti sottostanti della parete toracica (stadio 3). Nelle forme più avanzate, si diffonde ad altre parti del corpo (stadio 4), diventando metastatico [1].

Nel 2020 sono state 54976 le nuove diagnosi di tumore al seno, rappresentando il 30.3 % di tutti i tumori femminili e il 14.6 % di tutti i tumori diagnosticati in Italia.

Negli ultimi anni l'incidenza è in leggero aumento soprattutto nelle donne più giovani; tuttavia c'è una diminuzione della mortalità del 6 % (nel 2020 rispetto al 2015). Ciò nonostante rimane la prima causa di morte per tumore nelle donne [2].

L'analisi condotta in questa relazione si basa su uno studio attualmente in corso con la finalità di costruire un nomogramma; uno strumento che utilizza modelli matematici per prevedere la probabilità di un determinato esito clinico. Vengono dunque utilizzate varie caratteristiche cliniche delle pazienti per calcolare la probabilità di avere un linfonodo non sentinella positivo.

Nel primo capitolo viene presentata la patologia e lo studio condotto; nel secondo invece vengono analizzate le relazioni tra le variabili. Nel terzo capitolo viene studiata la relazione tra le caratteristiche cliniche e la proporzione di linfonodi non sentinella con lo scopo di calcolare la probabilità di avere un linfonodo non sentinella positivo.

Capitolo 1

Tumore al seno

1.1 Carcinoma della mammella

Con il termine di carcinoma della mammella ci si riferisce a un gruppo ampio ed eterogeneo di neoplasie epiteliali, invasive e non, che originano dagli elementi ghiandolari della mammella.

Tutti i tumori invasivi (Invasive Breast Cancer, IBC) sono raggruppati, a scopi terapeutici, nei seguenti gruppi in base ai biomarker ER e ERBB2 (HER2): ER-positivo, HER2-negativo; ER-positivo, HER2-positivo; ER-negativo, HER2-positivo; ER-negativo, HER2-negativo. Questi gruppi presentano distinti outcome e risposta alla terapia.

IBC può svilupparsi in qualsiasi quadrante della mammella, ma più frequentemente nel supero-esterno [3]. Esso è il cancro maggiormente diagnosticato nelle femmine (24% di tutti i tumori) e, nel mondo, la principale causa di morte per tumore nelle femmine [4].

IBC rappresenta l'11.6% dei tumori in entrambi i sessi, essendo il secondo tipo di tumore più frequente in assoluto [4, 5, 6]. Negli ultimi decenni l'incidenza di IBC è in aumento nei paesi con reddito basso e medio, mentre nei paesi ad alto reddito è diminuita, grazie alla riduzione dell'uso della terapia ormonale postmenopausale dagli anni 2000 [7, 8, 9]. Nonostante ciò, l'invecchiamento della popolazione causa un aumento globale dell'incidenza. Nel 2018 si sono registrati 2.1 milioni di nuovi casi di IBC e 627000 morti nel mondo [4].

L'eziologia di IBC è multifattoriale. Molti studi confermano il ruolo di ormoni, dieta, fattori riproduttivi e genetici come fattori di rischio. Tra tutti spicca il così detto stile

di vita occidentale: dieta ad alto contenuto calorico, ricca in proteine e grassi animali, combinata a scarsa attività fisica, obesità, aumento dell'età alla prima gravidanza, bassa natalità e riduzione della lunghezza del periodo di allattamento. Altri fattori di rischio sono la minore età di comparsa del menarca [10, 11] e l'uso di ormoni sessuali esogeni (estrogeni e progestinici) [12]. L'incidenza aumenta molto negli anni precedenti alla menopausa (circa 8% all'anno) rispetto ai successivi (circa 2% all'anno) [13]. Più di altri tipi di tumori, IBC è influenzato dalla familiarità. Due geni (BRCA1 e BRCA2) aumentano di molto il rischio di sviluppo di IBC.

La patogenesi di IBC segue diverse pathways, molecolari e genetiche. Esistono due modelli molecolari: il primo, ER-positivo, riconosce diverse entità (atipia epiteliale piatta, iperplasia duttale atipica e carcinoma duttale in situ ER-positivo) come precursori non obbligati di IBC. Il secondo, modello ER-negativo, prevede il carcinoma duttale in situ ER-negativo e l'adenosi micro-ghiandolare come precursori di IBC ER-negativi.

A livello cellulare esistono due modelli di cancerogenesi: a evoluzione sporadica clonale e quello della cellula neoplastica staminale.

Nelle popolazioni non sottoposte a screening preventivo, il più frequente segno clinico di IBC è una massa palpabile alla mammella. Possono essere presenti anche retrazione cutanea, inversione del capezzolo, differenza nella forma e nella dimensione della mammella o cambiamenti nel colore e nell'aspetto della cute sovrastante, fino all'ulcerazione nei casi estremi. Tutti questi segni clinici possono essere causati anche da neoplasie benigne della mammella, perciò è essenziale una valutazione tramite esami di imaging e, successivamente, la valutazione istologica tramite biopsia per una corretta diagnosi.

Nelle popolazioni sottoposte a screening IBC può presentarsi come una massa spigolata con o senza calcificazioni, distorsione dell'architettura della mammella, massa circoscritta o sole calcificazioni.

Istologicamente il IBC ha un ampio spettro morfologico. Devono essere considerate quattro caratteristiche istologiche per determinare la biologia di IBC: il sottotipo istologico (determinato da architettura, caratteristiche cito-nucleari e stromali), il grado di Nottingham (score basato sul punteggio di tre fattori: percentuale di formazione di strutture ghiandolari da parte della neoplasia, pleomorfismo nucleare e conta mitotica), presenza o assenza di diffusione angio-linfatica, associazione con componente in situ. Altre caratteristiche importanti nella classificazione sono la dimensione maggiore del tumore, la distanza dai margini di resezione chirurgica, linfociti infiltranti il tumore (TILS).

I biomarker vengono valutati grazie a colorazioni speciali immunoistochimiche.

L'espressione nucleare di ER è utile nel predire la risposta della neoplasia alla terapia

endocrina, viene espressa in percentuale di cellule neoplastiche con colorazione nucleare sul totale delle cellule neoplastiche.

L'espressione di PR è utilizzata per stratificare le neoplasie ER-positive dal punto di vista prognostico. Anche in questo caso l'espressione è nucleare e viene riportata come percentuale di cellule neoplastiche positive sul totale delle cellule neoplastiche.

HER2 appartiene alla famiglia dei recettori di fattori di crescita che regolano la normale proliferazione, lo sviluppo e la sopravvivenza cellulare. HER2 è espresso a basso livello sulla membrana cellulare dell'epitelio normale della mammella. In circa il 10-20% di IBC il gene HER2 è amplificato, creando una overespressione della proteina HER2 sulla superficie cellulare. Questa fornisce alla neoplasia un comportamento biologico più aggressivo dovuto a maggior proliferazione neoplastica, maggior motilità cellulare e maggior angiogenesi. Ci sono diversi farmaci usati in combinazione con la chemioterapia classica, che agiscono in modo mirato sul recettore HER2, bloccandone la funzione, tra cui trastuzumab, e aumentando la sopravvivenza delle pazienti. La valutazione dello stato di HER2 può essere svolta con metodica basata sull'immunoistochimica o sull'ibridazione in situ. Nella prima metodica, più rapida ed economica, il risultato è basato sulla percentuale e sull'intensità della colorazione della membrana citoplasmatica delle cellule neoplastiche (0 e 1+, gene non amplificato, 2+ equivoco, 3+ gene amplificato). La seconda metodica è riservata ai casi in cui il risultato dell'immunoistochimica è equivoco e consente di verificare meglio l'amplificazione del gene HER2.

1.1.1 Linfonodo sentinella

Prima dell'introduzione della biopsia del linfonodo sentinella la dissezione ascellare era il trattamento di elezione per IBC. Nonostante la dissezione ascellare fornisca informazioni sul più importante fattore prognostico, lo stato linfonodale, circa l'80% delle pazienti andava incontro a qualche complicanza [14], tra cui riduzione della mobilità dell'arto, formazione di sieroma, intorpidimento e perdita di sensibilità o edema all'arto, tutte di difficile gestione. La biopsia del linfonodo sentinella ha cambiato la terapia del IBC: grazie all'approccio mini-invasivo si sono ridotte morbidità e mortalità.

Veronesi et al. [15] hanno confrontato la dissezione ascellare completa con la biopsia del linfonodo sentinella alla quale si aggiungeva la dissezione ascellare completa solo nel caso di riscontro di metastasi al linfonodo sentinella. I risultati dello studio affermano che la biopsia del linfonodo sentinella predice in modo accurato la presenza di metastasi ascellare nel 96.9% delle pazienti, con un indice di falsi negativi dell' 8.8%. Alcuni trial hanno riscontrato meno problematiche di mobilità del braccio e della spalla, edema e

perdita di sensibilità dopo la biopsia del linfonodo sentinella, che si traduce in maggiore qualità di vita e benessere psicologico delle pazienti.

Il concetto di linfonodo sentinella si basa su due principi: l'esistenza di un'architettura di drenaggio linfatico ordinata e prevedibile a una regione di linfonodi e l'efficiente funzione di filtro per cellule tumorali del primo linfonodo. Esso si basa sulla teoria di Halsted che indica l'importanza del trattamento locoregionale nella terapia dei tumori, che diffondono a fasi. Altre ipotesi suggeriscono che il coinvolgimento linfonodale da parte della neoplasia possa essere indice di diffusione a distanza; perciò la biopsia del linfonodo sentinella è anche un metodo di stadiazione delle pazienti per la selezione di trattamenti sistemici adiuvanti.

Lo sviluppo della biopsia del linfonodo sentinella applicata al cancro della mammella è iniziato nel 1991 negli Stati Uniti. Ad oggi esistono diverse metodologie basate su due tecniche di mappaggio linfatico diverse: la prima usa un colloide radiomarcato per la determinazione intraoperatoria; la seconda sfrutta la linfoscintigrafia preoperatoria, sempre con colloide radiomarcato.

Questa tecnica ha rappresentato un importante sviluppo scientifico per le donne con IBC in stadi iniziali ed è la best practice standard di cura nelle pazienti con linfonodi clinicamente negativi all'ascella.

1.2 I dati

Il dataset fa riferimento a uno studio attualmente in corso, il cui scopo è costruire un nomogramma attualmente non utilizzato nell'ospedale di Padova. Un nomogramma è uno strumento che utilizza modelli matematici per prevedere la probabilità di un determinato esito clinico [16]. Ad esempio, il nomogramma più utilizzato è il MD Anderson Cancer Center [17]. Esso utilizza vari parametri clinico-patologici delle pazienti per stimare il rischio di metastasi, supportando così la decisione di sottoporsi a un ulteriore intervento chirurgico. Nel caso in esame, i nomogrammi sono impiegati per stimare la probabilità di avere un linfonodo non sentinella positivo.

I dati sono stati raccolti da gennaio 2015 ad agosto 2023 all'ospedale di Padova e includono 237 pazienti.

Le variabili considerate in questo studio sono 14 e rappresentano le caratteristiche cliniche delle pazienti. Le variabili considerate sono:

- *Età intervento*: variabile quantitativa, rappresenta l'età che aveva il paziente quando è stato sottoposto all'intervento (in anni).

- *Sede*: variabile qualitativa, rappresenta la localizzazione della neoplasia all'interno della mammella. Sono state distinte 6 zone:
 - superiore: assume valore 1.
 - inferiore: assume valore 2.
 - esterno: assume valore 3.
 - interno: assume valore 4.
 - centrale: assume valore 5.
 - diffuso: assume valore 6.
- *Dimensione meta sln*: variabile quantitativa, rappresenta la dimensione della metastasi all'interno del linfonodo sentinella espressa in millimetri.
- *estemporaneo*: variabile dicotomica, rappresenta un esame su materiale congelato che viene svolto dal patologo e assume valore 1 se è stato effettuato e 0 altrimenti.
- *Perc sln*: variabile quantitativa, rappresenta la proporzione di linfonodi sentinella positivi.
- *Perc non sln*: variabile quantitativa, rappresenta la proporzione di linfonodi non sentinella positivi.
- *Istotipo*: variabile qualitativa, rappresenta il tipo di tumore della mammella. È una classificazione fatta sull'aspetto della neoplasia al microscopio; ne influenza il comportamento biologico. Essa viene suddivisa in 6 categorie:
 - 1: duttale infiltrante.
 - 2: intraduttale.
 - 3: duttale infiltrante con componente intraduttale.
 - 7: intraduttale microinfiltrante.
 - 8: misto.
 - 9: altro.
- *ER*: variabile quantitativa, rappresenta la proporzione di cellule che esprimono recettori per gli estrogeni. Questo valore è ottenuto attraverso colorazione immunostochimica, che consente di visualizzare l'intensità della colorazione, indicativa della quantità di recettori presenti nelle cellule [18].

- *PR*: variabile quantitativa, rappresenta la proporzione di cellule che esprimono recettori per il progesterone, una proteina che regola la crescita delle cellule. Anche la quantità di *PR* viene determinata tramite colorazione immunohistochimica.
- *G*: variabile qualitativa, rappresenta il grado del tumore. Il parametro viene assegnato considerando tre variabili del tumore (dimensioni del nucleo, quantità di tubuli formati dal tumore, numero di mitosi). Più è alto, più è aggressiva la neoplasia. La variabile assume 3 valori:
 - 1: grado basso.
 - 2: grado intermedio.
 - 3: grado alto.
- *T*: variabile qualitativa, rappresenta la dimensione maggiore del tumore all'interno della mammella. Più alto è, più è aggressiva la neoplasia. Essa assume valore:
 - T1a: da 0,1 cm a 0,5 cm
 - T1b: da 0,5 cm a 1 cm
 - T1c: da 1cm a 2 cm
 - T2: da 2 cm a 5 cm
 - T3: da 5 cm
- *MIB1*: variabile quantitativa, rappresenta la proliferazione cellulare della neoplasia. Anche la quantità di *MIB1* viene determinata tramite colorazione immunohistochimica.
- *N0*: variabile dicotomica, assume valore 1 se non è presente nessun linfonodo metastatico e 0 altrimenti.
- *ERB*: variabile qualitativa, rappresenta la percentuale dell'espressione del recettore del fattore di crescita EGF. Questo recettore è coinvolto nella regolazione della crescita e proliferazione cellulare. La sua espressione anomala è spesso associata a tumori. I livelli di espressione di HER2 sono categorizzati come:
 - 0: meno del 10 % di cellule neoplastiche positive, nessuna colorazione visibile.
 - 1: colorazione incompleta.
 - 2: colorazione debole o moderata.
 - 3: colorazione completa.

1.2.1 Dati mancanti

All'interno del dataset sono presenti diversi valori mancanti:

- La variabile *età intervento* ha un valore mancante.
- La variabile *dimensione meta sln* ha 31 valori mancanti. Questo è dovuto al fatto che alcuni dati erano codificati come < 2 o > 2 ma non era possibile rendere la variabile dicotomica in quanto veniva persa troppa informazione. Per questo motivo si è preferito eliminare tali valori.
- La variabile *MIB1* ha un valore mancante.
- La variabile *Sede* ha un valore mancante.
- Nella variabile *Istotipo* sono stati esclusi i gruppi con valore 2 e 8 in quanto avevano solo 3 osservazioni per gruppo e non sarebbe stato possibile effettuare delle stime attendibili.
- Nella variabile *G* ci sono 8 valori mancanti.
- Nella variabile *T* ci sono 5 valori mancanti.

Oltre a questi, sono state eliminate 5 osservazioni in quanto avevano tra i 5 e i 7 valori mancanti.

Infine nella variabile *perc non sln* sono presenti 34 osservazioni aventi 0 linfonodi non sentinella positivi e 0 linfonodi sentinella negativi. Per questo motivo, queste osservazioni sono state escluse in quanto non era possibile calcolare la proporzione di linfonodi non sentinella positivi.

Durante l'analisi esplorativa i valori mancanti sono stati esclusi. Nella fase di costruzione del modello di regressione logistica, invece, i valori mancanti delle variabili qualitative sono stati sostituiti con la moda, mentre quelli delle variabili quantitative con la mediana.

Capitolo 2

Analisi esplorative


In questo capitolo sono riportate alcune analisi esplorative tramite le quali si potranno indagare eventuali relazioni tra le variabili in esame. Le analisi sono state eseguite per mezzo del software R in versione 4.2.3 (<https://www.r-project.org/>).

Il livello di significatività è fissato al 5 %.


	Min.	1st Qu.	Mediana(IQR)	Media(sd)	3rd Qu.	Max
<i>età intervento</i>	32	50	58 (19)	59.12 (12.372)	69	88
<i>dimensione meta sln</i>	0.023	2	5 (7)	5.867 (5.019)	9	25
<i>perc sln</i>	0	1	1 (0)	0.938 (0.184)	1	1
<i>perc non sln</i>	0	0	0 (0.167)	0.149 (0.27)	0.167	1
<i>ER</i>	0	0.9	0.9 (0.1)	0.873 (0.243)	1	1
<i>PR</i>	0	0.163	0.7 (0.738)	0.577 (0.378)	0.9	1
<i>MIB1</i>	0	0.16	0.25 (0.17)	0.256 (0.135)	0.33	0.8

TABELLA 2.1: Tabella di sintesi delle variabili quantitative


La variabile *età intervento* ha una distribuzione simmetrica, come evidenziato dal boxplot (*Figura 2.1*). La variabile ha un valore minimo di 32 anni e un massimo di 88 anni. La mediana è 58 anni (IQR = 19), mentre la media è 59.12 anni (sd = 12.372).

FIGURA 2.1: Boxplot della variabile *età intervento*


La variabile *dimensione meta sln* presenta un'assimmetria positiva (*Figura 2.2*), si notano inoltre la presenza di 2 valori anomali. Il valore minimo è 0.023 mm e un valore massimo di 25 mm. La mediana è 5 mm (IQR = 7) mentre la media è 5.861 mm (sd = 5.019).

FIGURA 2.2: Boxplot della variabile *dimensione meta sln*


La variabile *perc sln* presenta un'assimmetria negativa (*Figura 2.3*), si notano anche 6 outliers. Il valore minimo è 0 e il valore massimo è 1. La mediana è 1 (IQR = 0) mentre la media è 0.938 (sd = 0.184). Si nota inoltre una maggiore densità di valori verso il valore 1.

FIGURA 2.3: Boxplot della variabile *perc sln*


La variabile *perc non sln* presenta un'assimmetria negativa (*Figura 2.4*), si notano anche 9 valori anomali. Il valore minimo è 0 e il valore massimo è 1. La mediana è 0 (IQR = 0.166) mentre la media è 0.149 (sd = 0.27). Si nota una prevalenza di valori verso lo zero.

FIGURA 2.4: Boxplot della variabile *perc non sln*


La variabile *ER* presenta una forte asimmetria negativa (*Figura 2.5*), sono inoltre presenti 7 valori anomali. Il valore minimo è 0 e il valore massimo è 1. La mediana è 0.9 (IQR = 0.1) mentre la media è 0.873 (sd = 0.242).

FIGURA 2.5: Boxplot della variabile *ER*

La variabile *PR* presenta un'asimmetria negativa (*Figura 2.6*). Il valore minimo è 0 e il valore massimo è 1. La mediana è 0.7 (IQR = 0.737) mentre la media è 0.577 (sd = 0.377).

FIGURA 2.6: Boxplot della variabile *PR*

La variabile *MIB1* è simmetrica (*Figura 2.7*), sono presenti 3 valori anomali. Il valore minimo è 0 e il valore massimo è 0.8. La mediana è 0.25 (IQR = 0.17) mentre la media è 0.256 (sd = 0.134).

FIGURA 2.7: Boxplot della variabile *MIB1*

Per la variabile *Sede* (Tabella 2.2) il 53% delle pazienti ha la neoplasia situata nella parte superiore della mammella (Figura 2.8). Solo il 4.8% delle pazienti ha la neoplasia situata nella zona superiore della mammella.

	Superiore	Inferiore	Esterno	Interno	Centrale	Diffuso
Frequenza assoluta	101	36	19	9	13	11
Frequenza relativa	0.534	0.19	0.101	0.048	0.069	0.058

TABELLA 2.2: Frequenze assolute e relative della variabile *Sede*

Nella variabile *estemporaneo* (Tabella 2.3) si nota come nel 78.9% delle pazienti sia stato eseguito l'esame su materiale congelato (Figura 2.9).

	No	Si
Frequenza assoluta	40	150
Frequenza relativa	0.211	0.789

TABELLA 2.3: Frequenze assolute e relative della variabile *estemporaneo*




FIGURA 2.8: Barplot della variabile *sede*




FIGURA 2.9: Barplot della variabile *estemporaneo*

Per la variabile *Istotipo* (Tabella 2.4) il 46.8% delle pazienti ha un istotipo duttale infiltrante con componente intraduttale (Figura 2.10). Solo il 2.6% ha un istotipo classificato come "altro".



	duttale infiltrante	duttale infiltrante con componente intraduttale	lobulare infiltrante	altro
Frequenza assoluta	53	89	43	5
Frequenza relativa	0.279	0.468	0.226	0.027

TABELLA 2.4: Frequenze assolute e relative della variabile *Istotipo*

Per la variabile *G* (Tabella 2.5) il 57.3% delle pazienti ha un grado intermedio (Figura 2.11). Solo il 13.7% delle pazienti ha un grado basso.

	Grado basso	Grado intermedio	Grado alto
Frequenza assoluta	25	101	56
Frequenza relativa	0.132	0.573	0.295

TABELLA 2.5: Frequenze assolute e relative della variabile *G*

FIGURA 2.10: Barplot della variabile *istotipo*FIGURA 2.11: Barplot della variabile *G*



Per la variabile *T* (Tabella 2.6) il 43.2% delle pazienti appartiene alla categoria T1c o T2 (Figura 2.12). Solo il 2.3% delle pazienti appartiene alla categoria T3.

	T1a	T1b	T1c	T2	T3
Frequenza assoluta	6	15	80	80	4
Frequenza relativa	0.032	0.081	0.432	0.432	0.023

TABELLA 2.6: Frequenze assolute e relative della variabile *T*

Per la variabile *N0* (Tabella 2.7) l'88.9% delle pazienti ha almeno un linfonodo metastatico (Figura 2.13).

	Presente	Assente
Frequenza assoluta	169	21
Frequenza relativa	0.889	0.111

TABELLA 2.7: Frequenze assolute e relative della variabile *N0*FIGURA 2.12: Barplot della variabile *T*FIGURA 2.13: Barplot della variabile *N0*

Per la variabile *ERB* (Tabella 2.8) il 44.7% delle pazienti ha una colorazione incompleta (Figura 2.14). Solo il 5% delle pazienti ha colorazione completa.

	minore del 10%	colorazione incompleta	colorazione debole o moderata	completa
Frequenza assoluta	64	85	31	10
Frequenza relativa	0.337	0.447	0.163	0.053

TABELLA 2.8: Frequenze assolute e relative della variabile *ERB*




FIGURA 2.14: Barplot della variabile *ERB*

2.1 Analisi bivariate

In questa sezione vengono valutate le relazioni tra le varie variabili. Delle 91 coppie bivariate, 22 sono risultate significative e vengono dunque riportate.

Dal diagramma di dispersione (Figura 2.15) tra le variabili *ER* ed *età intervento* si nota una leggera correlazione positiva. La correlazione di Spearman è 0.214 (p-value=0.003), indicando una relazione significativa positiva tra le due variabili; dunque all'aumentare dell'età del paziente aumentano i recettori dell'estrogeno.




FIGURA 2.15: Diagramma di dispersione tra *età intervento* ed *ER*, con curva LOESS in rosso e intervallo di confidenza al 95% in grigio

Dal diagramma di dispersione (*Figura 2.16*) tra le variabili *dimensione meta sln* e *perc non sln* si nota una correlazione positiva. La correlazione di Spearman è 0.404 (p-value < 0.001), indicando una significativa relazione positiva tra le due variabili; dunque all'aumentare della dimensione della metastasi all'interno del linfonodo sentinella aumenta la proporzione di linfonodi non sentinella positivi.




FIGURA 2.16: Diagramma di dispersione tra *dimensione meta sln* ed *perc non sln*, con curva LOESS in rosso e intervallo di confidenza al 95% in grigio

Dal diagramma di dispersione (*Figura 2.17*) tra le variabili *PR* e *MIB1* si nota una leggera correlazione negativa. La correlazione di Spearman è -0.146 (p-value = 0.045), dunque all'aumentare del recettore del progesterone diminuisce la proliferazione della neoplasia.




FIGURA 2.17: Diagramma di dispersione tra *PR* ed *MIB1*, con curva LOESS in rosso e intervallo di confidenza al 95% in grigio

Dal diagramma di dispersione (*Figura 2.18*) tra le variabili *ER* e *PR* si nota una correlazione positiva. La correlazione di Spearman è 0.423 (p-value < 0.001), dunque all'aumentare dei recettori dell'estrogeno aumentano i recettori del progesterone.




FIGURA 2.18: Diagramma di dispersione tra *ER* ed *PR*, con curva LOESS in rosso e intervallo di confidenza al 95% in grigio

Dal diagramma di dispersione (*Figura 2.19*) tra le variabili *ER* e *MIB1* si nota una leggera correlazione negativa. La correlazione di Spearman è -0.166 (p-value = 0.023), dunque all'aumentare dei recettori dell'estrogeno diminuisce la proliferazione della neoplasia.




FIGURA 2.19: Diagramma di dispersione tra *ER* ed *MIB1*, con curva LOESS in rosso e intervallo di confidenza al 95% in grigio

Il test del χ^2 per verificare l'indipendenza tra le variabili *sede* ed *estemporaneo* (Tabella 2.9) porta a un valore osservato pari a 10.647 e un rispettivo p-value di 0.056, indicando un'indipendenza tra le variabili.

Estemporaneo	Sede					
	1	2	3	4	5	6
0	21 (11.111 %)	2 (1.058 %)	7 (3.703 %)	2 (1.058 %)	5 (2.645 %)	3 (1.587 %)
1	80 (42.328 %)	34 (17.989 %)	12 (6.349 %)	7 (3.703 %)	8 (4.232 %)	8 (4.232 %)

TABELLA 2.9: Tabella di contingenza tra *Estemporaneo* e *Sede*

Il test del χ^2 per verificare l'indipendenza tra le variabili *T* ed *estemporaneo* (Tabella 2.10) porta a un valore osservato pari a 22.585 e un rispettivo p-value prossimo allo zero, portando a rifiutare l'ipotesi di indipendenza.

Estemporaneo	T				
	T1a	T1b	T1c	T2	T3
0	0 (0 %)	8 (4.324 %)	23 (12.432 %)	7 (3.783 %)	0 (0 %)
1	6 (3.243 %)	7 (3.783 %)	57 (30.810 %)	73 (39.459 %)	4 (2.162 %)

TABELLA 2.10: Tabella di contingenza tra *Estemporaneo* e *T*

L'applicazione del test del χ^2 di indipendenza tra le variabili *Estemporaneo* ed *ERB* (Tabella 2.11) porta a un valore osservato della statistica test pari a 11.997 e un rispettivo p-value di 0.007. Questo conferma la presenza di una relazione tra le due variabili.

Estemporaneo	ERB			
	0	1	2	3
0	10 (5.263 %)	23 (12.105 %)	2 (1.052 %)	5 (2.631 %)
1	54 (28.421 %)	62 (32.631 %)	29 (15.263 %)	5 (2.631 %)

TABELLA 2.11: Tabella di contingenza tra *Estemporaneo* e *ERB*

Il test del χ^2 per verificare l'indipendenza tra le variabili *istotipo* e *T* (Tabella 2.12) porta a un valore osservato pari a 20.283 e un rispettivo p-value di 0.071, suggerendo un'indipendenza tra le due variabili.

Istotipo	T				
	T1a	T1b	T1c	T2	T3
1	2 (1.081 %)	1 (0.540 %)	24 (12.972 %)	25 (13.513 %)	0 (0 %)
3	2 (1.081 %)	13 (7.027 %)	36 (19.459 %)	34 (18.378 %)	1 (0.540 %)
7	2 (1.081 %)	1 (0.540 %)	16 (8.648 %)	20 (10.810 %)	3 (1.621 %)
9	0 (0 %)	0 (0 %)	4 (2.162 %)	1 (0.540 %)	0 (0 %)

TABELLA 2.12: Tabella di contingenza tra *Istotipo* e *T*

L'applicazione del test del χ^2 di indipendenza tra le variabili *G* ed *T* (Tabella 2.13) porta a un valore osservato della statistica test pari a 27.362 e un rispettivo p-value di 0.001. Questo conferma la presenza di una relazione tra le due variabili.

G	T				
	T1a	T1b	T1c	T2	T3
1	2 (1.129 %)	6 (3.389 %)	14 (7.909 %)	3 (1.694 %)	0 (0 %)
2	3 (1.694 %)	8 (4.519 %)	46 (25.988 %)	39 (22.033 %)	3 (1.694 %)
3	1 (0.564 %)	1 (0.564 %)	16 (9.039 %)	34 (19.209 %)	1 (0.564 %)

TABELLA 2.13: Tabella di contingenza tra *G* e *T*

Il test del χ^2 per verificare l'indipendenza tra le variabili *G* e *ERB* (Tabella 2.14) porta a un valore osservato pari a 23.296 e un rispettivo p-value prossimo allo zero, indicando un'associazione tra queste variabili.

G	ERB			
	0	1	2	3
1	11 (6.043 %)	12 (6.593 %)	2 (1.098 %)	0 (0 %)
2	26 (14.285 %)	58 (31.868 %)	14 (7.692 %)	3 (1.648 %)
3	24 (13.186 %)	13 (7.142 %)	12 (6.593 %)	7 (3.846 %)


TABELLA 2.14: Tabella di contingenza tra G e ERB

L'applicazione del test del χ^2 di indipendenza tra le variabili ERB ed $N0$ (Tabella 2.15) porta a un valore osservato della statistica test pari a 8.9705 e un rispettivo p-value di 0.035. Questo conferma la presenza di una relazione tra le due variabili.

ERB	N0	
	0	1
0	52 (27.368 %)	12 (6.315 %)
1	76 (40 %)	9 (4.736 %)
2	31 (16.315 %)	0 (0 %)
3	10 (5.263 %)	0 (0 %)

TABELLA 2.15: Tabella di contingenza tra $N0$ e ERB

Viene studiata la distribuzione della variabile *dimensione meta sln* condizionata alla variabile G . Dal boxplot in Figura 2.20 si nota come lo scarto interquartile aumenta all'aumentare di G ; in particolare, passa da 3.9 nel gruppo 1 a 8.125 nel gruppo 3.

FIGURA 2.20: Boxplot della variabile *dimensione meta sln* condizionato alla variabile G

L'ipotesi di uguaglianza delle distribuzioni è stata verificata attraverso il test di Kruskal-Wallis. Il test porta a un valore osservato della statistica test pari a 6.972 e un relativo p-value pari a 0.031 che porta a rifiutare l'ipotesi di uguaglianza delle distribuzioni. In altre parole, i dati suggeriscono che le distribuzioni di *dimensione meta sln* non sono uguali tra i vari gruppi di *G*.

Nell'analisi post-hoc (*Tabella 2.16*) è risultata una differenza nella distribuzione condizionata tra il gruppo con un grado del tumore basso rispetto al gruppo con grado alto, anche se l'evidenza non è forte. Non risultano significative le differenze nelle altre distribuzioni.

	Basso	Intermedio
Intermedio	0.263	-
Alto	0.053	0.087

TABELLA 2.16: Risultati delle analisi post hoc con correzione di Holm

Viene valutata la differenza nella distribuzione della variabile *perc non sln* rispetto alla presenza o meno di un linfonodo metastatico. Dal boxplot (*Figura 2.21*) si nota come tutti i pazienti non aventi un linfonodo metastatico hanno lo 0 % di linfonodi non sentinella positivi ad eccezione di due outlier.




FIGURA 2.21: Boxplot della variabile *perc non sln* condizionato alla variabile *N0*

L'applicazione del test di Mann-Whitney per verificare l'uguaglianza delle due distribuzioni porta a un valore osservato della statistica test pari a 2393 e un rispettivo p-value di 0.003; confermando la differenza nelle due distribuzioni.

Per quanto riguarda la variabile *perc non sln* condizionata alla variabile *T* si nota che i pazienti con dimensione maggiore del tumore compresa tra 1 cm e 2 cm (T1b) non

hanno nemmeno un linfonodo sentinella positivo, ad eccezione di due outliers (*Figura 2.22*).




FIGURA 2.22: Boxplot della variabile *perc non sln* condizionato alla variabile *T*


L'ipotesi di uguaglianza delle distribuzioni è stata verificata attraverso il test di Kruskal-Wallis. Il test porta a un valore osservato della statistica test pari a 13.716 e un relativo p-value pari a 0.008 che porta a rifiutare l'ipotesi di uguaglianza delle distribuzioni.

Nell'analisi post-hoc (*Tabella 2.17*) l'unica differenza tra le distribuzioni risultata significativa è stata tra il gruppo T1b e il gruppo T3.

	T1a	T1b	T1c	T2
T1b	1.000	-	-	-
T1c	1.000	1.000	-	-
T2	1.000	0.127	0.127	-
T3	0.734	0.044	0.134	1.000

TABELLA 2.17: Risultati delle analisi post hoc con correzione di Holm

È stata analizzata la distribuzione della variabile *MIB1* condizionata alla localizzazione della neoplasia all'interno della mammella (*Figura 2.23*).

FIGURA 2.23: Boxplot della variabile *MIB1* condizionato alla variabile *sede*


L'applicazione del test di Kruskal-Wallis per verificare l'uguaglianza delle distribuzioni in tutti i gruppi porta a un valore osservato della statistica test 14.246 e un rispettivo p-value pari a 0.014.

L'analisi post-hoc (Tabella 2.18) mostra una differenza significativa nella propagazione della neoplasia tra i pazienti con neoplasia localizzata nella zona interna e quelli con neoplasia diffusa.

	Superiore	Inferiore	Esterno	Interno	Centrale
Inferiore	0.80	-	-	-	-
Esterno	1.00	1.00	-	-	-
Interno	0.30	1.00	1.00	-	-
Centrale	1.00	0.89	1.00	0.42	-
Diffuso	0.42	0.17	0.29	0.05	1.00

TABELLA 2.18: Risultati delle analisi post hoc con correzione di Holm

Viene analizzata la distribuzione della variabile *MIB1* condizionata alla variabile *istotipo*. Dal boxplot (*Figura 2.24*) si nota come la mediana del gruppo 9 sia maggiore del terzo quartile del gruppo 7 e coincida col terzo quartile del gruppo 1.

FIGURA 2.24: Boxplot della variabile *MIB1* condizionato alla variabile *istotipo*


L'applicazione del test di Kruskal-Wallis per verificare l'uguaglianza delle distribuzioni in tutti i gruppi porta a un valore osservato della statistica test 11.181 e un rispettivo p-value pari a 0.011.

L'analisi post-hoc (*Tabella 2.19*) mostra una differenza significativa nelle distribuzioni del gruppo 3 (duttale infiltrante) e del gruppo 7 (lobulare). Le altre distribuzioni non risultano differenti.

	Duttale	Duttale infiltrante	Lobulare
Duttale infiltrante	0.405	-	-
Lobulare	0.405	0.018	-
Altro	0.405	0.405	0.229

TABELLA 2.19: Risultati delle analisi post hoc con correzione di Holm

Viene analizzata la distribuzione condizionata della variabile *MIB1* condizionata alla variabile *G*. Dal boxplot (*Figura 2.25*) si nota come il primo quartile del gruppo 3 sia maggiore del terzo quartile sia del gruppo 1 sia del gruppo 3.

FIGURA 2.25: Boxplot della variabile *MIB1* condizionato alla variabile *G*


L'applicazione del test di Kruskal-Wallis per verificare l'uguaglianza delle distribuzioni in tutti i gruppi porta a un valore osservato della statistica test di 50.793 e un rispettivo p-value prossimo allo zero.

L'analisi post-hoc (*Tabella 2.20*) mostra come tutte le distribuzioni condizionate siano diverse tra di loro.

	Basso	Intermedio
Intermedio	0.02	-
Alto	< 0.001	< 0.001

TABELLA 2.20: Risultati delle analisi post hoc con correzione di Holm

Viene analizzata la distribuzione della variabile *MIB1* condizionata alla variabile *ERB*. Dal boxplot (*Figura 2.26*) si nota come il terzo quartile del gruppo 1 sia minore della mediana del gruppo 2 e del primo quartile del gruppo 3.

FIGURA 2.26: Boxplot della variabile *MIB1* condizionato alla variabile *ERB*


L'applicazione del test di Kruskal-Wallis porta a un valore osservato della statistica test pari a 18.454 e un rispettivo p-value prossimo allo zero.

L'analisi post-hoc (*Tabella 2.21*) mostra una differenza significativa tra il gruppo 0 (< 10%) e 3 (completa), 1 (incompleta) e 2 (debole), 1 (incompleta) e 3 (completa).

	< 10%	Incompleta	Debole
Incompleta	0.212	-	-
Debole	0.176	0.007	-
Completa	0.046	0.003	0.212

TABELLA 2.21: Risultati delle analisi post hoc con correzione di Holm

Viene analizzata la distribuzione della variabile *ER* condizionata alla variabile *G*. Dal boxplot (*Figura 2.27*) si nota come la mediana del gruppo 3 coincida con il primo quartile del gruppo 1 e 2.

FIGURA 2.27: Boxplot della variabile ER condizionato alla variabile G


L'applicazione del test di Kruskal-Wallis porta a un valore osservato pari a 11.612 e un rispettivo p-value di 0.003.

L'analisi post-hoc (*Tabella 2.22*) mostra una differenza significativa tra il gruppo con grado intermedio e il gruppo con grado alto. La differenza tra il gruppo con grado basso e grado alto non è risultata significativa, anche se l'evidenza a favore non è marcata.

	Basso	Intermedio
Intermedio	0.789	-
Alto	0.052	0.003

TABELLA 2.22: Risultati delle analisi post hoc con correzione di Holm

Viene analizzata la distribuzione condizionata della variabile ER condizionata alla variabile ERB . Dal boxplot (*Figura 2.28*) si nota come la mediana del gruppo 0,2 e 3 coincidano con il primo quartile del gruppo 1. Si nota anche un aumento dello scarto interquartilico. Esso infatti è pari a 0.1 per il gruppo 0, 1 e 2 mentre per il gruppo 3 è pari a 0.288.

FIGURA 2.28: Boxplot della variabile *ER* condizionato alla variabile *ERB*


L'applicazione del test di Kruskal-Wallis porta a un valore osservato pari a 9.285 e un rispettivo p-value di 0.026.

L'analisi post-hoc (*Tabella 2.23*) mostra una differenza significativa tra il gruppo 1 (incompleta) e il gruppo 3 (completa). Le altre distribuzioni risultano uguali.

	< 10%	Incompleta	Debole
Incompleta	0.599	-	-
Debole	0.993	0.626	-
Completa	0.115	0.018	0.165

TABELLA 2.23: Risultati delle analisi post hoc con correzione di Holm

Viene analizzata la distribuzione della variabile *PR* condizionata alla variabile *G*. Dal boxplot (*Figura 2.29*) si nota come la distanza interquartilica sia diversa nei 3 gruppi. Essa infatti è pari a 0.4 nel gruppo 1, 0.55 nel gruppo 2 e 0.893 nel gruppo 3.

FIGURA 2.29: Boxplot della variabile PR condizionato alla variabile G

L'applicazione del test di Kruskal-Wallis porta a un valore osservato della statistica test pari a 6.044 e un rispettivo p-value di 0.049.

Tuttavia l'analisi post-hoc (*Tabella 2.24*) mostra che nessuna delle coppie di gruppi risulta significativamente diversa.

Quindi, anche se il test globale suggerisce una differenza. Tuttavia, i confronti a coppie non identificano chiaramente quali gruppi siano responsabili di questa differenza.

	Basso	Intermedio
Intermedio	0.639	-
Alto	0.099	0.085

TABELLA 2.24: Risultati delle analisi post hoc con correzione di Holm

Capitolo 3

Nomogramma

In questo capitolo viene applicato un modello lineare generalizzato per studiare in che modo viene influenzata la probabilità di avere un linfonodo non sentinella positivo in relazione alle altre variabili concomitanti.

3.1 Modelli lineari generalizzati

I modelli lineari generalizzati (GLM) rappresentano un'estensione del modello lineare normale e servono per trattare le distribuzioni che possono essere differenti dalla distribuzione normale. Il modello lineare generalizzato è definito da 3 elementi:

- La distribuzione di probabilità della variabile risposta Y_i deve appartenere alla famiglia di dispersione esponenziale. Si assume inoltre che le variabili casuali $Y_1, \dots, Y_n$ siano indipendenti con media $\mu_i = \mathbb{E}[Y_i]$, $i = 1, \dots, n$.
- Il predittore lineare è dato da $\eta = X\beta$, con $\beta = (\beta_1, \dots, \beta_p)^\top$ coefficienti di regressione del modello.
- La funzione di legame [19] è la funzione che lega la media della variabile risposta μ_i al predittore lineare η_i . Si assume che essa sia nota, derivabile e invertibile:

$$g(\mu_i) = \eta_i = x_i\beta$$

Perché una distribuzione appartenga alla famiglia di dispersione esponenziale, la sua densità deve essere esprimibile nella forma

$$p(y_i; \theta_i, \phi) = \exp \left\{ \frac{\theta_i y_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right\}$$

con $y_i \in S \subseteq \mathbb{R}$, $\theta_i \in \Theta \subseteq \mathbb{R}$ e $a_i(\phi) > 0$.

3.2 Modelli per dati binari

I modelli per dati binari fanno parte dei GLM. Essi vengono impiegati quando la variabile risposta è dicotomica, come nel caso in esame. Questi modelli sono ampiamente utilizzati in diversi ambiti, tra cui quello medico [20], epidemiologico [21] e genetico [22].

I dati possono essere in due forme:

- dati non raggruppati, quando il vettore delle risposte assume valore 0 o 1.
- dati raggruppati, quando viene riportato il numero totale di successi e il numero totale di osservazioni.

Nel caso in esame, i dati sono in forma raggruppati; infatti, per ogni paziente è riportata la proporzione di linfonodi non sentinella positivi ossia il rapporto tra i linfonodi non sentinella positivi e il numero di linfonodi non sentinella esaminati.

Si assume che la variabile risposta sia data da $y_i = s_i/m_i$, dove s_i rappresenta il numero di successi e m_i rappresenta il numero di osservazioni per ciascuna combinazione. Nel caso in esame y_i rappresenta la proporzione di linfonodi positivi, s_i rappresenta il numero di linfonodi non sentinella positivi e m_i rappresenta il numero di linfonodi non sentinella esaminati. Si assume dunque che $m_i Y_i \sim Bi(m_i, \mu_i)$, $i = 1, \dots, n$ dove μ_i rappresenta la probabilità di successo per la i -esima osservazione.

Si assume inoltre che

$$g(\mu_i) = \eta_i = x_i \beta,$$

con $g(\mu_i)$ funzione di legame. La funzione di legame più utilizzata nei modelli per dati binari è la funzione di legame logistica o logit che assume

$$g(\mu_i) = \log \left(\frac{\mu_i}{1 - \mu_i} \right)$$

con inversa

$$\mu_i = \frac{e^{x_i \beta}}{1 + e^{x_i \beta}}$$

Quando viene utilizzata la funzione di legame logistica, la quota $\mu_i/(1 - \mu_i)$ rappresenta il rapporto tra la probabilità di successo e di insuccesso. Il generico coefficiente β_r esprime dunque l'effetto sul logaritmo della quota di un incremento unitario di x_{ir} fermo restando il valore delle altre variabili esplicative.

Le altre possibili funzioni di legame sono la funzione di legame probit ($g(\mu_i) = \Phi^{-1}(\mu_i)$ dove $\Phi(\mu_i)$ rappresenta la funzione di ripartizione della normale standard), la funzione di legame log-log complementare ($g(\mu_i) = \log(-\log(1 - \mu_i))$) e la funzione di legame cauchit ($g(\mu_i) = \tan(\pi(\mu_i - 0.5))$).

3.2.1 Applicazione del modello ai dati

Per valutare l'esistenza di una relazione tra la proporzione di linfonodi non sentinella positivi e le altre variabili esplicative viene adattato un modello di regressione binomiale.

Come scelta per la funzione di legame, si considera la funzione di legame logistica.

Il modello è stato identificato per mezzo di una selezione in avanti, ossia inserendo nel modello passo per passo tutte le variabili esplicative aventi p-value minori di 0.05. Vengono dunque escluse tutte le variabili che non hanno un contributo significativo nel spiegare il fenomeno analizzato.

Nel caso in esame sono risultate significative, in ordine di inserimento, le variabili *dimensione meta sln* (p-value ≈ 0), *N0* (p-value ≈ 0), *istotipo* (p-value ≈ 0), *sede* (p-value ≈ 0), *PR* (p-value ≈ 0), *perc sln* (p-value = 0.027) e la variabile *G* (p-value = 0.013).

Il modello teorico risultante prevede

$$\begin{aligned} \text{logit}(\mu_i) = & \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i5} + \beta_6 x_{i6} + \beta_7 x_{i7} + \beta_8 x_{i8} \\ & + \beta_9 x_{i9} + \beta_{10} x_{i10} + \beta_{11} x_{i11} + \beta_{12} x_{i12} + \beta_{13} x_{i13} + \beta_{14} x_{i14}, \end{aligned}$$

dove x_{i1} rappresenta la variabile *dimensione meta sln*, $x_{i2} = 1$ se la variabile *N0* assume valore 1 e 0 altrimenti, $x_{i3} = 1$ se la variabile *istotipo* assume valore 3 e 0 altrimenti, $x_{i4} = 1$ se la variabile *istotipo* assume valore 7 e 0 altrimenti, $x_{i5} = 1$ se la variabile *istotipo* assume valore 9 e 0 altrimenti, $x_{i6} = 1$ se la variabile *sede* assume valore 2 e 0 altrimenti, $x_{i7} = 1$ se la variabile *sede* assume valore 3 e 0 altrimenti, $x_{i8} = 1$ se la variabile *sede* assume valore 4 e 0 altrimenti, $x_{i9} = 1$ se la variabile *sede* assume valore 5 e 0 altrimenti, $x_{i10} = 1$ se la variabile *sede* assume valore 6 e 0 altrimenti, x_{i11} rappresenta la variabile *PR*, x_{i12} rappresenta la variabile *perc sln*, $x_{i13} = 1$ se la variabile *G* assume valore 2 e $x_{i14} = 1$ se la variabile *G* assume valore 3.

Il modello stimato è riportato in *Tabella 3.1*.

	Stima	Errore Std	IC 0.95	z value	p-value
Intercetta	-4.675	0.677	(-6.059, -3.400)	-6.910	< 0.001
Dimensione meta sln	0.165	0.015	(0.136, 0.194)	11.127	< 0.001
N01	-2.819	0.605	(-4.249, -1.795)	-4.658	< 0.001
Istotipo3	-0.862	0.175	(-1.205, -0.520)	-4.934	< 0.001
Istotipo7	0.410	0.192	(0.035, 0.786)	2.141	0.032
Istotipo9	-2.900	0.774	(-4.779, -1.598)	-3.747	< 0.001
Sede2	-0.008	0.178	(-0.362, 0.338)	-0.045	0.964
Sede3	0.373	0.248	(-0.124, 0.851)	1.504	0.133
Sede4	-1.320	0.461	(-2.322, -0.488)	-2.865	0.004
Sede5	0.711	0.267	(0.178, 1.227)	2.662	0.008
Sede6	-1.899	0.398	(-2.753, -1.176)	-4.775	< 0.001
PR	0.965	0.196	(0.586, 1.353)	4.936	< 0.001
Perc sln	1.326	0.548	(0.309, 2.468)	2.420	0.016
G2	0.360	0.313	(-0.223, 1.010)	1.150	0.250
G3	0.732	0.324	(0.124, 1.400)	2.262	0.024

TABELLA 3.1: Adattamento del modello di regressione

$$\begin{aligned}
\text{logit}(\hat{\mu}_i) = & -4.675 + 0.165x_{i1} - 2.819x_{i2} - 0.008x_{i3} + 0.373x_{i4} - 1.320x_{i5} + 0.711x_{i6} \\
& - 1.899x_{i7} - 0.862x_{i8} + 0.410x_{i9} - 2.900x_{i10} + 0.965x_{i11} + 1.326x_{i12} \\
& + 0.360x_{i13} + 0.732x_{i14}
\end{aligned}$$

I coefficienti del modello sono interpretabili come il logaritmo del rapporto delle quote (*Tabella 3.2*). Per quanto riguarda le variabili quantitative, prendendo come esempio la variabile *dimensione meta sln*, essa ha un coefficiente pari a 0.165. Pertanto, l'odds ratio corrispondente, calcolato come $e^{0.165} = 1.179$, indica un aumento dell'odds ratio del 17.9 % per ogni incremento unitario della variabile. Invece, per quanto riguarda le variabili qualitative, prendendo come esempio la variabile *sede*; essa ha un coefficiente pari a -0.008 quando assume valore 2 e -1.32 quando assume valore 4. I relativi odds ratio sono quindi $e^{-0.008} = 0.992$ quando assume valore 2 e $e^{-1.32} = 0.267$ quando assume valore 4, indicando una diminuzione dell'odds ratio del 0.8 % quando la variabile assume valore 2 rispetto alla categoria di riferimento 1 e una diminuzione dell'odds ratio del 73.3 % quando assume valore 4 rispetto alla categoria di riferimento 1. In questo caso il parametro associato alla variabile *Sede* quando assume valore 2 non è risultato

significativo, indicando che la differenza tra quando la variabile assume valore 2 e quando assume valore 1 non è significativa.

Variabile	$\exp(\hat{\beta})$	IC 2.5%	IC 97.5%
Dimensione meta sln	1.179	1.146	1.214
N01	0.060	0.014	0.166
Istotipo3	0.422	0.300	0.595
Istotipo7	1.507	1.036	2.196
Istotipo9	0.055	0.008	0.202
Sede2	0.992	0.697	1.402
Sede3	1.452	0.883	2.342
Sede4	0.267	0.098	0.614
Sede5	2.035	1.194	3.411
Sede6	0.150	0.064	0.308
PR	2.626	1.796	3.869
Perc sln	3.765	1.362	11.799
G2	1.433	0.800	2.747
G3	2.079	1.132	4.057

TABELLA 3.2: Stime degli odds ratio con intervalli di confidenza al 95%

Per valutare la bontà di adattamento del modello viene applicato il test del log-rapporto di verosimiglianza per confrontare il modello stimato con il modello avente solo l'intercetta. L'applicazione del test porta a un valore osservato della statistica test pari a 332.77 e un relativo p-value prossimo allo zero, portando a rifiutare la nullità di tutti i coefficienti.

La devianza residua (686,17) è circa quattro volte i gradi di libertà (175). Il test per verificare la presenza di sovradisersione porta a un valore osservato pari a 796.716 e un rispettivo p-value prossimo allo zero, confermando la presenza di sovradisersione.

L'analisi dei residui di Pearson mostra un allontanamento dall'ipotesi di normalità come evidenziato dal Q-Q plot (*Figura 3.1*). L'applicazione del test di Shapiro-Wilk porta a un valore osservato della statistica test pari a 0.889 e un rispettivo p-value prossimo allo zero, confermando l'allontanamento dall'ipotesi di normalità.




FIGURA 3.1: Q-Q plot dei residui

L'adeguatezza del modello viene inoltre valutata attraverso la sua capacità predittiva tramite l'analisi della curva ROC (*Figura 3.2*). L'area sotto tale curva (AUC) è pari a 0.77, indicando una moderata adeguatezza del modello.




FIGURA 3.2: Curva ROC e relativo AUC

Successivamente, è stata determinata la soglia ottimale di cut-off utilizzando il metodo di Youden, risultata pari a 0.124. Ciò significa che un paziente con una probabilità stimata maggiore o uguale a 0.124 viene considerato malato. Utilizzando tale soglia si è ottenuta la seguente matrice di confusione (*Tabella 3.3*):

Stimato	Osservato	
	Sano	Malato
Sano	81	25
Malato	33	51

TABELLA 3.3: Matrice di confusione

Utilizzando questa soglia, il modello ha un'accuratezza pari a 0.695, una sensibilità di 0.711 e una specificità di 0.671. Ne derivano un tasso di falsi positivi del 32.9 % e un tasso di falsi negativi del 28.9 %. Il Kappa di Cohen è risultato pari a 0.375, indicando un moderato accordo tra valori stimati e osservati.

Il test di Hosmer-Lemeshow porta a un valore osservato pari a 13.033 e un rispettivo p-value pari a 0.111, confermando non ci sia una differenza significativa tra le frequenze osservate e le frequenze attese.

Gli studi presenti in letteratura hanno evidenziato un odds ratio molto simile per la variabile *Dimensione meta sln*. Le variabili *Istotipo* e *PR* non sono risultate significative. La variabile *Sede* non è stata considerata, mentre al posto della variabile *Perc SLN* è stato utilizzato il numero assoluto di linfonodi sentinella positivi. Sono invece risultate significativamente associate alla condizione in esame la presenza di invasione linfovaskolare, l'estensione extranodale e la multifocalità [23, 24].

Tuttavia, la presenza di sovradisersione, che comporta una sottostima della variabilità della variabile risposta, insieme a un valore moderato del coefficiente kappa di Cohen e a una frequenza non trascurabile di falsi positivi e negativi, evidenzia alcune limitazioni nella bontà di adattamento del modello. Questi elementi indicano un adattamento non ottimale, sottolineando la necessità di ulteriori approfondimenti in studi futuri.

Capitolo 4

Conclusioni

Questo studio mostra come la probabilità di avere un linfonodo non sentinella positivo dipenda dalla dimensione della metastasi all'interno del linfonodo sentinella, dalla proporzione di linfonodi sentinella positivi, dalla proporzione di cellule che esprimono recettori per il progesterone, dalla localizzazione della neoplasia all'interno della mammella, dalla tipologia del tumore, dal grado del tumore e dalla presenza o meno di metastasi.

Si è visto che la probabilità di avere un linfonodo non sentinella positivo aumenta con l'incremento della dimensione della metastasi all'interno del linfonodo sentinella, della proporzione dei linfonodi sentinella positivi e del recettore del progesterone. Si è visto anche che tale probabilità diminuisce nelle pazienti che hanno la neoplasia nella zona interna del seno o diffusa rispetto alle pazienti aventi la neoplasia nella zona superiore del seno. Essa invece aumenta nei pazienti aventi la neoplasia nella zona centrale del seno rispetto alle pazienti aventi la neoplasia localizzata nella zona superiore. Si è visto anche che la probabilità diminuisce nei pazienti aventi istotipo duttale infiltrante con componente intraduttale o con valore 'altro' rispetto ai pazienti con istotipo duttale infiltrante; tale probabilità aumenta nelle pazienti con istotipo lobulare infiltrante rispetto alle pazienti con istotipo duttale infiltrante. Infine, si è visto che all'aumentare del grado del tumore la probabilità di avere un linfonodo non sentinella aumenta, anche se la differenza tra le pazienti aventi grado basso e grado intermedio non è risultata significativa.

Per futuri studi si consiglia di aumentare la numerosità campionaria, aggiungere altre caratteristiche cliniche come l'identificazione di qualche estensione extranodale nei linfonodi positivi e la presenza o meno di cellule tumorali nei vasi sanguigni o nelle strutture linfatiche.

In sintesi, questo studio ha fornito importanti indicazioni sui fattori clinici e patologici che determinano la probabilità di positività dei linfonodi non sentinella nelle pazienti con carcinoma mammario. Sebbene questi risultati abbiano rilevanza per la gestione clinica, la ricerca futura, con un ampliamento della numerosità campionaria, potrà ulteriormente chiarire il ruolo di questi fattori nella predizione e nella personalizzazione del trattamento.

Bibliografia

- [1] Fondazione Veronesi. Tumore al seno - glossario delle malattie, 2025.
- [2] Fondazione AIRC per la Ricerca sul Cancro. Tumore del seno - guida ai tumori, 2025.
- [3] CJ Bright, DW Rea, A Francis, and RG Feltbower. Comparison of quadrant-specific breast cancer incidence trends in the united states and england between 1975 and 2013. *Cancer Epidemiology*, 44:186–194, Oct 2016.
- [4] F Bray, M Laversanne, H Sung, J Ferlay, RL Siegel, I Soerjomataram, and A Jemal. Global cancer statistics 2022: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA Cancer Journal for Clinicians*, 74(3):229–263, May-Jun 2024.
- [5] ME Work, IL Andrulis, EM John, JL Hopper, Y Liao, FF Zhang, JA Knight, DW West, RL Milne, GG Giles, TA Longacre, F O’Malley, AM Mulligan, MC Southey, H Hibshoosh, and MB Terry. Risk factors for uncommon histologic subtypes of breast cancer using centralized pathology review in the breast cancer family registry. *Breast Cancer Research and Treatment*, 134(3):1209–1220, Aug 2012.
- [6] CI Li, DJ Uribe, and JR Daling. Clinical characteristics of different histologic types of breast cancer. *British Journal of Cancer*, 93(9):1046–1052, Oct 2005.
- [7] Breast Cancer Linkage Consortium. Cancer risks in brca2 mutation carriers. *Journal of the National Cancer Institute*, 91(15):1310–1316, 1999.
- [8] CE DeSantis, F Bray, J Ferlay, J Lortet-Tieulent, BO Anderson, and A Jemal. International variation in female breast cancer incidence and mortality rates. *Cancer Epidemiology, Biomarkers & Prevention*, 24(10):1495–1506, Oct 2015.
- [9] JE Rossouw, GL Anderson, RL Prentice, AZ LaCroix, C Kooperberg, ML Stefanick, RD Jackson, SA Beresford, BV Howard, KC Johnson, JM Kotchen, and

- J Ockene. Risks and benefits of estrogen plus progestin in healthy postmenopausal women: principal results from the women's health initiative randomized controlled trial. *JAMA*, 288(3):321–333, Jul 2002.
- [10] PA Newcomb, A Trentham-Dietz, JM Hampton, KM Egan, L Titus-Ernstoff, SW Andersen, ER Greenberg, and WC Willett. Late age at first full term birth is strongly associated with lobular breast cancer. *Cancer*, 117(9):1946–1956, May 2011.
- [11] GK Reeves, K Pirie, J Green, D Bull, and V Beral. Reproductive factors and specific histological types of breast cancer: prospective study and meta-analysis. *British Journal of Cancer*, 100(3):538–544, Feb 2009.
- [12] IARC Working Group on the Evaluation of Carcinogenic Risks to Humans. Pharmaceuticals, 2012. IARC Monographs on the Evaluation of Carcinogenic Risks to Humans, Volume 100A, pp. 1–401.
- [13] GA Colditz and B Rosner. Cumulative risk of breast cancer to age 70 years according to risk factor status: data from the nurses' health study. *American Journal of Epidemiology*, 152(10):950–964, Nov 2000.
- [14] DN Krag, DL Weaver, H Takamaru, T Ashikaga, F Moffat, SV Klimberg, and et al. The sentinel node in breast cancer: a multicenter validation study. *New England Journal of Medicine*, 339(14):941–946, 1998.
- [15] U Veronesi, G Paganelli, G Viale, A Luini, S Zurrida, V Galimberti, and et al. A randomized comparison of sentinel-node biopsy with routine axillary dissection in breast cancer. *New England Journal of Medicine*, 349:546–553, 2003.
- [16] University of Nebraska Medical Center. Breast cancer survival estimator, 2025. accesso 26 Marzo 2025.
- [17] MD Anderson Cancer Center. Breast cancer sentinel lymph node nomogram, 2025. accesso 26 Marzo 2025.
- [18] D.C. Allred, J.M. Harvey, M. Berardo, and G.M. Clark. Assessment of estrogen receptor status in breast cancer. *Journal of Clinical Oncology*, 22(2):201–208, 2004.
- [19] A. Salvan, N. Sartori, and L. Pace. *Modelli Lineari Generalizzati*. Springer, 2020. Cap 3.

-
- [20] L. Ventura and W. Racugno. *Biostatistica. Casi di Studio in R*. Egea, Milano, 2020.
- [21] Annette J. Dobson and Adrian G. Barnett. *An Introduction to Generalized Linear Models*. Chapman and Hall/CRC, 4 edition, 2018. Cap 3.
- [22] J. Gilis, L. Perin, M. Malfait, K. Van den Berge, A. T. Assefa, B. Verbist, D. Risso, and L. Clement. Differential detection workflows for multi-sample single-cell rna-seq data. *bioRxiv*, 2023.
- [23] K. J. Van Zee, D.-M. E. Manasseh, J. L. B. Bevilacqua, S. K. Boolbol, J. V. Fey, L. K. Tan, P. I. Borgen, H. S. Cody, and M. W. Kattan. A nomogram for predicting the likelihood of additional nodal metastases in breast cancer patients with a positive sentinel node biopsy. *Annals of Surgical Oncology*, 10(10):1140–1151, 2003.
- [24] B. Koca, B. Kuru, N. Ozen, S. Yoruker, and Y. Bek. A breast cancer nomogram for prediction of non-sentinel node metastasis - validation of fourteen existing models. *Asian Pacific Journal of Cancer Prevention*, 15(4):1481–1488, 2014.

